

Исследование состязательной устойчивости в реальном мире сверточных нейросетей

на примере систем детекции и распознавания лиц

Петюшко Александр

МГУ им. М.В.Ломоносова, к.ф.-м.н.
Video Intelligence and Fundamental Research Team Leader
Huawei, Intelligent Systems and Data Science Lab

15 апреля, 2021




- ① Лаборатория Интеллектуальных Систем и Науки о Данных
- ② Потрясающие успехи СНС в компьютерном зрении
- ③ (Не) устойчивость СНС в компьютерном зрении
- ④ Методы для генерации состязательных примеров в цифровой области
- ⑤ ℓ_0 -состязательные примеры
- ⑥ Методы для генерации состязательных примеров в реальном мире
- ⑦ Состязательные примеры для систем детекции лиц
- ⑧ Состязательные примеры для систем распознавания лиц
- ⑨ Защита от состязательных примеров в реальном мире
- ⑩ Black-box восстановление лица по вектору признаков



Научное сотрудничество: Лаборатория Интеллектуальных Систем и Науки о Данных


Российский исследовательский институт → Московский исследовательский институт → Лаборатория Интеллектуальных Систем и Науки о Данных



Развитие нейросетей

Начиная с 1943 года, когда впервые была предложена математическая формализация МакКалоком и Питтсом понятия “искусственного нейрона”, нейросети становились¹:

- Объемнее (содержали больше параметров),
- Глубже (содержали больше блоков вычислений),
- Лучше! (более правильно решали поставленные перед ними задачи)




¹Image credits: <https://arxiv.org/abs/1409.4842>



Сверточные нейросети²

- Для работы с фотографиями и видео лучше всего подходят сверточные нейронные сети (СНС),
- Например, позволяют выделять объекты и определять их класс,
- Ну и отвечают на главный вопрос – кошка или собака?



²Image credits: <https://adeshpande3.github.io/>, <https://stepupanalytics.com>



Интересные вопросы

Давайте разберемся, так ли уж хороши сверточные нейросети, действительно ли оправдано все то внимание, которое им уделяют?

Вопрос1

Как сейчас соотносится качество распознавания человеком и СНС для известных баз данных?

Вопрос2

Насколько устойчивы СНС по отношению к входным данным?
Легко ли их сломать?

CNN vs Human³



³Image credit: <https://spectrum.ieee.org>

Человек или СНС?

ImageNet⁴ (1000-классовая база данных изображений)

- Топ-5 ошибка для человека⁵: 5.1%
- Топ-5 ошибка для СНС⁶: 2.0%

LFW



Labeled Faces in the Wild⁷ (база данных лиц)

- Ошибка верификации для человека⁸: 2.47%
- Ошибка верификации для СНС⁹: 0.17%

⁴<http://www.image-net.org/>

⁵<http://karpathy.github.io/2014/09/02/>

[what-i-learned-from-competing-against-a-convnet-on-imagenet/](#)

⁶Touvron, Hugo, et al. "Fixing the train-test resolution discrepancy." 2019

⁷<http://vis-www.cs.umass.edu/lfw/>


⁸Kumar, Neeraj, et al. "Attribute and simile classifiers for face verification." 2009

⁹Deng, Jiankang, et al. "Arcface: Additive angular margin loss for deep face recognition." 2018



Такие неустойчивые СНС

- Можно внести практически незаметные для глаза человека возмущения во входные данные, которые, тем не менее, полностью поменяют выход нейронной сети
- Например, результат классификации с “панды” поменяется на “гиббона”¹⁰




Такое возмущение называется **состязательным примером** (adversarial perturbation / example / attack)

¹⁰Image credit: <https://arxiv.org/pdf/1412.6572.pdf>



Состязательные примеры в разных задачах

СНС для обнаружения и сегментации изображений¹¹:



И даже НС для вопросно-ответных систем (QA, question answering systems)¹²:

Article: Super Bowl 50

Paragraph: “Peyton Manning became the first quarterback ever to lead two different teams to multiple Super Bowls. He is also the oldest quarterback ever to play in a Super Bowl at age 39. The past record was held by John Elway, who led the Broncos to victory in Super Bowl XXXIII at age 38 and is currently Denver’s Executive Vice President of Football Operations and General Manager. Quarterback Jeff Dean had jersey number 37 in Champ Bowl XXXIV.”

Question: “What is the name of the quarterback who was 38 in Super Bowl XXXIII?”

Original Prediction: John Elway

Prediction under adversary: Jeff Dean



¹¹Xie C. et al. “Adversarial examples for semantic segmentation and object detection.” 2017

¹²Jia R. et al. “Adversarial examples for evaluating reading comprehension systems.” 2017



Одна из главных причин существования состязательных примеров

- Одна из основных причин такого поведения СНС на похожих изображениях — неустойчивость СНС
- А именно, разделяющие границы классификатора часто проходят очень близко к обучающим данным, и легко “заступить” за такую границу^{13,14}




¹³Image credit: <https://secml.github.io/>

¹⁴Fawzi, Alhussein, Seyed-Mohsen Moosavi-Dezfooli, and Pascal Frossard. “Robustness of classifiers: from to adversarial to random noise.” 2016

Простой метод защиты

- Поскольку можно изменить решение СНС путем небольшого пиксельного возмущения, то почему бы во время обучения для каждого обучающего примера не добавлять и всю его попиксельную окрестность (по некоторой норме, например, ℓ_∞)¹⁵



¹⁵ Madry, Aleksander, et al. "Towards deep learning models resistant to adversarial attacks." 2017



Простой, но не работающий метод защиты

- Предположим, что исходная картинка размера 100×100 пикселей, 3 цвета RGB
- Предположим, что наш глаз не сильно различает колебания цвета пикселей в 2 градации (из 256): в каждой точке для каждого цвета можем позволить ± 1 значение
- Тогда для каждого обучающего примера нужно добавить следующее количество его пиксельных соседей:

$$2^{3 \times 100 \times 100} = 2^{30000} = (2^{10})^{3000} \approx (10^3)^{3000} = 10^{9000}$$

- Это гораздо больше числа атомов в видимой части Вселенной (10^{80})!
- В общем, не очень реалистично



Работающий метод защиты

- Давайте не перебирать всю окрестность обучающего примера, а брать только те точки из окрестности, которые ближе всего к разделяющей поверхности
- Такой метод обучения называется состязательным (adversarial training)¹⁶

Плюсы состязательного обучения

- Не нужно перебирать всю окрестность огромной мощности
- В целом, защищает от метода нахождения состязательных примеров

Минусы состязательного обучения

- Процедура нахождения хороших состязательных примеров работает медленно (гораздо медленнее одного градиентного шага)
- Защищает **только** от того метода нахождения состязательных примеров, который использовался в состязательном обучении

¹⁶ Goodfellow, Ian J., Jonathon Shlens, and Christian Szegedy. "Explaining and harnessing adversarial examples." 2014



Состязательные примеры: необходимые обозначения

- Пусть $x \in B = [0, 1]^{C \times M \times N}$ — входная картинка $C \times M \times N$, где C — количество цветов (1 для ч/б, 3 для RGB)
- y — правильный класс для x
- θ — параметры СНС-классификатора
- $L(\theta, x, y)$ — функция потерь
- $f(x)$ — выход классификатора (распознанный класс); при обучении мы добиваемся равенства $f(x) = y$
- $r \in B = [0, 1]^{C \times M \times N}$ — аддитивная добавка ко входу x



Состязательный пример и устойчивость: формулировки

Цель состязательного примера

Поменять выход классификатора f на неправильный путем добавления минимального (по некоторой норме ℓ_p) возмущения r :

- ① $\|r\|_p \rightarrow \min$
- ② $f(x) = y$ (изначальный ответ СНС верный)
- ③ $f(x + r) \neq y$ (меняем выход с помощью возмущения r)
- ④ $x + r \in B$ (остаемся во множестве допустимых изображений)

Устойчивость классификатора

Найти такой класс возмущения $S(x, f) \subseteq B$, при котором классификатор не меняет свой выход:

$$f(x + r) = f(x) = y \quad \forall r \in S(x, f)$$

Состязательное обучение: формулировка

В обозначениях выше обычное обучение можно сформулировать как

Обучение на примерах

$$\min_{\theta} \mathbb{E}_{x,y} [L(\theta, x, y)]$$

В состязательном обучении¹⁷ мы сначала генерируем (например, каким-нибудь методом) самый сложный пример из некоторой окрестности Δ входного примера (например, по ℓ_p -норме), а уже затем минимизируем по параметрам нейросети:

Состязательное обучение

$$\min_{\theta} \mathbb{E}_{x,y} [\max_{r \in \Delta} L(\theta, x + r, y)]$$

¹⁷ Goodfellow, Ian J., Jonathon Shlens, and Christian Szegedy. "Explaining and harnessing adversarial examples." 2014



Нормы ℓ_p : напоминание

Напомним наиболее употребительные нормы ℓ_p для $x = (x_1, \dots, x_n) \in \mathbb{R}^n$:

- ℓ_2 : $\|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$
- ℓ_1 : $\|x\|_1 = \sum_{i=1}^n |x_i|$
- ℓ_∞ : $\|x\|_\infty = \max_i |x_i|$
- ℓ_0 : $\|x\|_0 = \sum_{i=1}^n \mathbf{1}_{x_i \neq 0}$

Замечание. Для $0 < p < 1$ норма ℓ_p , для которой $\|x\|_p = (\sum_{i=1}^n |x_i|^p)^{1/p}$, не является нормой



Классификация соляризаторных примеров (1)

По цели

- Ненаправленные (untargeted): нужно просто сменить ответ классификатора
- Направленные (targeted): нужно сменить на заранее определенный класс y_t

По осведомленности

- Открытые (white-box): генерирующий знает все о классификаторе (архитектуру и веса)
- Закрытые (black-box): генерирующий имеет частичную информацию о классификаторе (обычно только информацию о выходе)

По условию применения

- Цифровые (digital): для применения к фотографии
- Реальные (real-world): для применения к реальному объекту

Классификация состязательных примеров (2)

По универсальности

- Зависимые от входа (*input-aware*): возмущение r зависит от входа x
- Универсальные (*universal*): возмущение r работает для любого входа x

По переносимости

- Непереносимые (*non-transferable*): работают только для узкого класса классификаторов
- Переносимые (*transferable*): работают для широкого класса классификаторов (но при этом могут быть не универсальными)
- Наиболее сложный случай — направленный закрытый реальный универсальный переносимый состязательный пример
- В данной лекции будем рассматривать открытые состязательные примеры



Эффективность состязательных примеров

Введем простой критерий успешности (success) $S(A, Z)$ алгоритма A генерации состязательного примера $r_A(x)$ на множестве $Z \ni (x^i, y^i)$:

- В случае ненаправленного примера:

$$S(A, Z) = \frac{\sum_i \mathbf{1}\{f(x^i) = y^i\} \cdot \mathbf{1}\{f(x^i + r_A(x^i)) \neq y^i\}}{\sum_i \mathbf{1}\{f(x^i) = y^i\}}$$

- В случае направленного на класс y_t :


$$S(A, Z, y_t) = \frac{\sum_i \mathbf{1}\{f(x^i) = y^i\} \cdot \mathbf{1}\{f(x^i + r_A(x^i)) = y_t\}}{\sum_i \mathbf{1}\{f(x^i) = y^i\}}$$

Замечание. Очевидно, что $S(A, Z, y_t) \leq S(A, Z)$



Предтеча состязательных примеров

- Изначально устойчивость СНС изучалась с точки зрения адекватной реакции на разные входы
- Выяснилось, что существуют примеры (структурированные или нет), которые на выходе СНС могут давать с большой вероятностью любой класс
- Такие примеры назывались “обманными изображениями”¹⁸ (fooling images) и строились с помощью эволюционных алгоритмов



¹⁸Nguyen, Anh, Jason Yosinski, and Jeff Clune. "Deep neural networks are easily fooled: High confidence predictions for unrecognizable images." 2014

- Первый предложенный метод¹⁹ использовал ℓ_2 -норму для ограничения
- Рассматривались направленные примеры на класс $y_t \neq y$
- Функционал для минимизации с ограничением $x + r \in B$, $c = const$:

$$c\|r\|_2 + L(\theta, x, y_t) \rightarrow \min_r$$

- Для оптимизации использовался метод L-BFGS-B²⁰ (**L**imited memory **B**royden–**F**letcher–**G**oldfarb–**S**hanno algorithm with **B**ox constraints) — квази-Ньютоновский метод минимизации с ограничением на память и на переменные
- В какой-то мере примеры были переносимы на другие архитектуры

¹⁹Szegedy, Christian, et al. “Intriguing properties of neural networks.” 2013

²⁰Byrd, Richard H., et al. “A limited memory algorithm for bound constrained optimization.” 1995




Пример работы:

Школьный
автобус



$10 * r$



Страус



Переносимость:

	$FC10(10^{-4})$	$FC10(10^{-2})$	$FC10(1)$	$FC100-100-10$	$FC200-200-10$	$AE400-10$
$FC10(10^{-4})$	100%	11.7%	22.7%	2%	3.9%	2.7%
$FC10(10^{-2})$	87.1%	100%	35.2%	35.9%	27.3%	9.8%
$FC10(1)$	71.9%	76.2%	100%	48.1%	47%	34.4%
$FC100-100-10$	28.9%	13.7%	21.1%	100%	6.6%	2%
$FC200-200-10$	38.2%	14%	23.8%	20.3%	100%	2.7%
$AE400-10$	23.4%	16%	24.8%	9.4%	6.6%	100%

Метод генерации: CW



- Вспомним оптимизационную функцию: $c\|r\|_2 + L(\theta, x, y_t) \rightarrow \min_r$
- Поменяем функцию для направленных примеров: $f(x) = y_t \Leftrightarrow g(x) \leq 0$
 - Например, $g(x) = \max_{i \neq t} F(x)_i - F(x)_t$
 - где $F(x)$ — выход SoftMax (вероятности), или логиты на входе SoftMax
- Перейдем к формулировке $\|r\|_p + c \cdot g(x + r) \rightarrow \min_r$, где $x + r \in B$
- Такой метод называется CW²¹ (Carlini-Wagner) и хорошо работает на разных метриках ℓ_p
- В данном случае не оптимизируем глядя на прокси-функцию (функцию потерь), а смотрим на реальный выход (вероятности или логиты)

²¹ Carlini, Nicholas, and David Wagner. "Towards evaluating the robustness of neural networks." 2016



Метод генерации: DeepFool

- Идея: проецировать точку x_0 на разделяющую поверхность
- В случае линейного бинарного классификатора $\text{sign } f(x) = \text{sign}(w^T x + b)$:
 - Направление: $-\text{sign } f(x_0) \frac{w}{\|w\|_2}$
 - Длина: $\frac{|f(x_0)|}{\|w\|_2}$
 - \Rightarrow Возмущение: $r = -\frac{f(x_0)}{\|w\|_2^2} w$
- В случае нелинейной разделяющей поверхности $f(x)$:
 - применяем формулу Тейлора: $f(x) \approx f(x_0) + \nabla f(x_0)(x - x_0)$
 - и подставляем в формулу для r выражение $w = \nabla f(x_0)$



Метод генерации: DeepFool

- Итеративный алгоритм DeepFool²² для произвольного классификатора

Algorithm 1 DeepFool for binary classifiers

```
1: input: Image  $x$ , classifier  $f$ .  
2: output: Perturbation  $\hat{r}$ .  
3: Initialize  $x_0 \leftarrow x$ ,  $i \leftarrow 0$ .  
4: while  $\text{sign}(f(x_i)) = \text{sign}(f(x_0))$  do  
5:    $r_i \leftarrow -\frac{f(x_i)}{\|\nabla f(x_i)\|_2^2} \nabla f(x_i)$ ,  
6:    $x_{i+1} \leftarrow x_i + r_i$ ,  
7:    $i \leftarrow i + 1$ .  
8: end while  
9: return  $\hat{r} = \sum_i r_i$ .
```

- Существует естественное обобщение на случай многоклассового классификатора

²²Moosavi-Dezfooli, Seyed-Mohsen, Alhussein Fawzi, and Pascal Frossard. "Deepfool: a simple and accurate method to fool deep neural networks." 2015

Метод генерации: FGSM

- Несмотря на хорошую реализацию, метод L-BFGS-B не так быстр и требует внешнего (по отношению к исследуемой СНС) оптимизатора
- **Предложение:** использовать линейную часть функции потерь в окрестности x и идти по градиенту — FGSM²³ (**Fast Gradient Sign Method**):

$$r = \epsilon \cdot \text{sign}(\nabla_x L(\theta, x, y_t))$$

где $0 < \epsilon < 1$ — некоторая константа

- **Напоминание:** для оптимизации весов СНС применяется метод обратного распространения ошибок, где берется градиент по весам СНС, т.е. $\nabla_{\theta} L(\theta, x, y)$
- Теперь исследуется норма возмущения ℓ_{∞}

²³Goodfellow, Ian J., Jonathon Shlens, and Christian Szegedy. "Explaining and harnessing adversarial examples." 2014



Метод генерации: I-FGSM (PGD)

- Часто линейная оценка окрестности функции достаточно грубая, и один шаг FGSM порой не приводит к хорошему примеру
- Для этого применяют итеративный метод I-FGSM²⁴ (Iterative FGSM), который позволяет двигаться в сторону границы классификатора более точно
- Если Π_B — проекция на B , то в случае ненаправленных примеров

$$x^{n+1} = \Pi_B(x^n + \text{sign } \nabla_x L(\theta, x, y)), \quad x^0 = x$$

- Если принять $\|x - x_{adv}\|_\infty \leq \epsilon$, то авторы предлагают делать $n = \min(256\epsilon + 4, 320\epsilon)$ шагов
- Этот метод также называется PGD (Projected Gradient Descent)

²⁴Kurakin, Alexey, Ian Goodfellow, and Samy Bengio. "Adversarial examples in the physical world." 2016



- **Замечание:** Методы генерации все больше похожи на шаги оптимизатора
- **Идея:** давайте использовать сглаживание градиента — MI-FGSM²⁵ (Momentum I-FGSM)

Algorithm 1 MI-FGSM

Input: A classifier f with loss function J ; a real example \mathbf{x} and ground-truth label y ;

Input: The size of perturbation ϵ ; iterations T and decay factor μ .

Output: An adversarial example \mathbf{x}^* with $\|\mathbf{x}^* - \mathbf{x}\|_\infty \leq \epsilon$.

```
1:  $\alpha = \epsilon/T$ ;  
2:  $\mathbf{g}_0 = 0$ ;  $\mathbf{x}_0^* = \mathbf{x}$ ;  
3: for  $t = 0$  to  $T - 1$  do  
4:   Input  $\mathbf{x}_t^*$  to  $f$  and obtain the gradient  $\nabla_{\mathbf{x}} J(\mathbf{x}_t^*, y)$ ;  
5:   Update  $\mathbf{g}_{t+1}$  by accumulating the velocity vector in the  
gradient direction as
```

$$\mathbf{g}_{t+1} = \mu \cdot \mathbf{g}_t + \frac{\nabla_{\mathbf{x}} J(\mathbf{x}_t^*, y)}{\|\nabla_{\mathbf{x}} J(\mathbf{x}_t^*, y)\|_1}; \quad (6)$$

```
6:   Update  $\mathbf{x}_{t+1}^*$  by applying the sign gradient as  

$$\mathbf{x}_{t+1}^* = \mathbf{x}_t^* + \alpha \cdot \text{sign}(\mathbf{g}_{t+1}); \quad (7)$$

```

```
7: end for  
8: return  $\mathbf{x}^* = \mathbf{x}_T^*$ .
```

²⁵Dong, Yinpeng, et al. "Boosting adversarial attacks with momentum." 2017



Сравнение FGSM-like методов

	Attack	Inc-v3	Inc-v4	IncRes-v2	Res-152	Inc-v3 _{ens3}	Inc-v3 _{ens4}	IncRes-v2 _{ens}
Inc-v3	FGSM	72.3*	28.2	26.2	25.3	11.3	10.9	4.8
	I-FGSM	100.0*	22.8	19.9	16.2	7.5	6.4	4.1
	MI-FGSM	100.0*	48.8	48.0	35.6	15.1	15.2	7.8
Inc-v4	FGSM	32.7	61.0*	26.6	27.2	13.7	11.9	6.2
	I-FGSM	35.8	99.9*	24.7	19.3	7.8	6.8	4.9
	MI-FGSM	65.6	99.9*	54.9	46.3	19.8	17.4	9.6
IncRes-v2	FGSM	32.6	28.1	55.3*	25.8	13.1	12.1	7.5
	I-FGSM	37.8	20.8	99.6*	22.8	8.9	7.8	5.8
	MI-FGSM	69.8	62.1	99.5*	50.6	26.1	20.9	15.7
Res-152	FGSM	35.0	28.2	27.5	72.9*	14.6	13.2	7.5
	I-FGSM	26.7	22.7	21.2	98.6*	9.3	8.9	6.2
	MI-FGSM	53.6	48.9	44.7	98.5*	22.1	21.7	12.9

Как видно, MI-FGSM — наиболее успешная методика генерации.



Метод генерации: JSMA

- JSMA²⁶ (Jacobian-based Saliency Map Attack) – один из первых ℓ_0 -методов, для которого важно количество задействованных в методе пикселей, а не их значения
- Идея: менять те пиксели, которые дают максимальный вклад в производную по входу для нужного класса для направленного примера
- Можно делать это итеративно, постепенно добавляя пиксели в активную область r
- Замечание: $F(x)$ – выход SoftMax слоя, пиксели добавляются парами (так проще)

Algorithm 3 Increasing pixel intensities saliency map
 $\nabla F(\mathbf{X})$ is the forward derivative, Γ the features still in the search space, and t the target class

Input: $\nabla F(\mathbf{X})$, Γ , t


```
1: for each pair  $(p, q) \in \Gamma$  do
2:    $\alpha = \sum_{i=p,q} \frac{\partial F_t(\mathbf{X})}{\partial \mathbf{X}_i}$ 
3:    $\beta = \sum_{i=p,q} \sum_{j \neq t} \frac{\partial F_j(\mathbf{X})}{\partial \mathbf{X}_i}$ 
4:   if  $\alpha > 0$  and  $\beta < 0$  and  $-\alpha \times \beta > \max$  then
5:      $p_1, p_2 \leftarrow p, q$ 
6:      $\max \leftarrow -\alpha \times \beta$ 
7:   end if
8: end for
9: return  $p_1, p_2$ 
```

²⁶Papernot, Nicolas, et al. “The limitations of deep learning in adversarial settings.” 2015



Метод генерации: One pixel

- Однопиксельный состязательный пример²⁷ — предельный случай ℓ_0 -метода генерации
- Идея: применить эволюционный алгоритм (дифференциальной эволюции²⁸)
- Популяция состоит из 400 экземпляров, каждый из которых задается пятеркой: две координаты и три канала цвета
- Генерация потомка — линейная комбинация трех случайных родителей



Original image (dog)

Target classes


²⁷Su, Jiawei, Danilo Vasconcellos Vargas, and Kouichi Sakurai. "One pixel attack for fooling deep neural networks." 2017

²⁸Storn, Rainer, and Kenneth Price. "Differential evolution — a simple and efficient heuristic for global optimization over continuous spaces." 1997



Универсальные состязательные примеры

- До этого все примеры строились как функция от входа x
- Однако можно строить т.н. “универсальный” пример²⁹, который будет уже функцией от всего обучающего множества X
- При построении примера будем искать r , примерно одинаково далекий от всех классов из X
- Справа — универсальное возмущение для любого входа, которое меняет выход классификатора





²⁹Moosavi-Dezfooli, Seyed-Mohsen, et al. “Universal adversarial perturbations.” 2016



Состязательные примеры для мультиклассового случая

- Если нужно распознавать несколько классов (а обычно так и бывает), то просто “сдвинуть” правильный класс с первого места по вероятности в некоторых задачах недостаточно
- В таком случае помогают т.н. “top- k состязательные примеры”³⁰, где $k > 1$
- В данной работе используются красивые геометрические концепты (биссектрисы для top- k классов)



³⁰Tursynbek N. et al. "Geometry-Inspired Top- k Adversarial Perturbations". 2020

Универсальные состязательные примеры для мультиклассового случая

- Удалось построить универсальный пример, обладающий тем же свойством — “сдвигающий” правильный класс за пределы top-k предсказаний по вероятности





Figure 7. Result of kUAP ($k = 3$) to different deep neural networks for ILSVRC2012



Классы методов генерации

В целом, можем поделить методы генерации состязательных примеров на следующие классы:

- На основе ℓ_2 -нормы (в т.ч. геометрические): наиболее удобные для классической оптимизации
- На основе ℓ_∞ -нормы: соответствуют процессу восприятия человеческим глазом визуальной информации
- На основе ℓ_0 -нормы: минимизируется область возмущения, но не ограничивается его сила

Тем не менее, для генерации физически реализуемых состязательных примеров этого мало.




Физические состязательные примеры

- Все состязательные примеры до этого работали в т.н. цифровой области (digital domain): изменяли картинку на уровне пикселей
- Если нет возможности изменить изображение непосредственно перед подачей в СНС, то такой метод бесполезен
- Поэтому состязательные примеры в реальном мире (real-world), или физические, наиболее универсальны
- Первый пример физических состязательных примеров³¹ — генерация для изображения в цифровой области, затем печать на физическом носителе (бумага), затем снимок цифровой камерой и последующая обработка СНС
- Никакой специальной технологии для генерации таких физических примеров еще не было, просто была показана их возможность

³¹Kurakin, Alexey, Ian Goodfellow, and Samy Bengio. "Adversarial examples in the physical world." 2016



Физические состязательные примеры



Физические состязательные примеры: EOT

- Не имеем доступа к фото (и его пикселям) \Rightarrow единственная возможность — это изменить внешний вид самого объекта
- Подход Expectation Over Transformation (EOT)³² учитывает, что объект в реальном мире обычно претерпевает ряд преобразований таких как:
 - Масштабирование
 - Трансляции и повороты
 - Изменение яркости и/или контрастности, шум и т.п.
- Т.о. для объекта x нужно найти состязательный пример r с учетом преобразований $g \in T$:

EOT


Найти $\arg \min_r \mathbb{E}_{g \sim T} [P(y|g(x+r))]$ для ненаправленного примера при условии:

- ① $\mathbb{E}_{g \sim T} [d(g(x+r), g(x))] < \epsilon$, где $d(a, b)$ – некоторая функция расстояния (например, $d(a, b) = \|a - b\|_p$)
- ② $x + r \in B$

³²Athalye A. et al. "Synthesizing robust adversarial examples." 2017

Физические состязательные примеры


Для ImageNet³³:



Для дорожных знаков³⁴:



3D-состязательные примеры:



³³Brown T. et al. "Adversarial patch." 2017

³⁴Eykholt K. et al. "Robust physical-world attacks on deep learning models." 2017

Физические состязательные примеры: основные ингридиенты

- ℓ_0 оптимизация (маска) + EOT: обязательно
- Total Variation (TV) функция потерь — штраф за негладкость примера (в реальном мире мало больших попиксельных градиентов):

$$TV(x) = \sum_{i,j} \sqrt{(x_{i,j+1} - x_{i,j})^2 + (x_{i+1,j} - x_{i,j})^2}$$

- Non-Printability Score (NPS) — штраф за использование цветов, которые не поддерживаются (принтером). Если $G \subset [0, 1]^3$ — поддерживаемая цветовая палитра (gamut), то штраф за использование цвета пикселя $q_0 \in [0, 1]^3$:

$$NPS(q_0) = \Pi_{q \in G} \|q - q_0\|_2$$

- Дополнительный маппинг цветов (например, принтер печатает не цвет c , а близкий $m(c)$, и это нужно учитывать)



Состязательные примеры для систем детекции и распознавания лиц

- Изначально т.н. **Camouflage Art**³⁵ использовался для обхода лидирующей системы детекции лиц Viola-Jones
- Это был вручную подобранный грим для обхода детектора Хаара
- Прорыв случился с работой Sharif et al.³⁶, где предложили использовать состязательные очки
- Использовано: ℓ_0 -оптимизация + ЕОТ + TV + NPS + цветовой маппинг
- Минусы: предобученные лица, системы распознавания лиц прошлого поколения



Состязательные очки




³⁵Feng R. et al. "Facilitating fashion camouflage art." 2013


³⁶Sharif M. et al. "Accessorize to a crime: Real and stealthy attacks on state-of-the-art face recognition." 2016



Общая схема детекции и распознавания лиц




Общая схема детекции и распознавания лиц



Детектор лиц: MTCNN³⁷

- В отличие от современных глубоких детекторов типа Faster RCNN или YOLO, MTCNN очень простой и неглубокий ⇒ меньше поле восприятия, сложнее поменять решение детектора
- В MTCNN каскадный подход: сначала грубое приближение (P-Net), а затем исправление (R-Net, O-Net)
- Решение: использовать для генерации состязательных примеров самый первый классификационный слой в P-Net (а не функции потерь для прямоугольников или ключевых точек)




³⁷Zhang K. et al. "Joint face detection and alignment using multitask cascaded convolutional networks." 2016.

Состязательные примеры для детектора лиц MTCNN

- EOT: Гауссов шум, размер маски, яркость, набор разных фото лица
- TV: +, NPS: -
- Маппинг цветов: штрафуем за близость к черному цвету ($x_{i,j} = 1$) \Rightarrow новая добавка в функцию потерь: $L_{BLK}(x) = \sum_{i,j} x_{i,j}$
- Оптимизатор: MI-FGSM


Схема генерации состязательных примеров для MTCNN




Состязательные примеры для детектора лиц MTCNN

- ℓ_0 -оптимизация: 2 версии
 - ➊ две раздельных маски на щеках
 - ➋ цельная медицинская маска
- У MTCNN маленькое поле восприятия \Rightarrow примеры не носят семантический характер
- Оценка параметров локальных аффинных проекций на основе заранее подготовленной специальной сетки для обучения

Примеры




Проекция



Состязательные примеры для детектора лиц MTCNN: результат

Детали: статья³⁸ (IEEE-2019) и видео-демонстрация³⁹.




³⁸Kaziakhmedov E. et al. "Real-world attack on MTCNN face detection system." 2019

³⁹<https://www.youtube.com/watch?v=0Y700IS8bxs>



Система распознавания лиц: ArcFace⁴⁰

- Выбрана ведущая открытая система распознавания лиц признаков: ArcFace
- Главная идея ArcFace — использовать угловое расстояние между векторами признаков
- Огромная обучающая база данных (MS1M) и глубокая СНС (ResNet-100)




⁴⁰Deng J. et al. "Arcface: Additive angular margin loss for deep face recognition." 2018



Состязательные примеры для распознавателя лиц ArcFace

- EOT: различные параметры проекций маски, одно изображение лица
- TV: +, NPS: -, цветовой маппинг: -
- Добавка к функции потерь $L_{sim}(x, x_{gt}) = \cos(\text{emb}(x), \text{emb}(x_{gt}))$ для работы с любым лицом, где x_{gt} — фото лица, $\text{emb}(x)$ — вектор признаков x
- Оптимизатор: MI-FGSM


Схема генерации состязательных примеров для ArcFace



Состязательные примеры для распознавателя лиц ArcFace

- ℓ_0 -оптимизация: цветная связная область (патч) в области лба
- Глубокая СНС \Rightarrow большое поле восприятия \Rightarrow семантический характер примера
- Т.н. “off-plane” нелинейная проекция:
 $(x, y, 0) \rightarrow (x', y, z'), z' = a \cdot x'^2$
- Дифференцируемый слой Spatial Transformer Layer⁴¹

$$x = a \cdot \left(|x'| \cdot \sqrt{(x')^2 + \frac{1}{4 \cdot a^2}} + \frac{1}{4 \cdot a^2} \cdot \ln \left(|x'| + \sqrt{(x')^2 + \frac{1}{4 \cdot a^2}} \right) - \frac{1}{4 \cdot a^2} \cdot \ln \left(\frac{1}{2 \cdot a} \right) \right)$$



Семантический характер примера



⁴¹Jaderberg M. et al. “Spatial transformer networks.” 2015

AdvHat — шапка-невидимка

Благодаря улучшенной процедуре проекции и полного использования цветовой палитры, состязательный пример устойчив к разным поворотам и освещенности

Анфас

(AdvHat: -)


Близость (оригинал): **0.61**

Анфас

(AdvHat: +)

Близость (оригинал): **0.02**

Близость (другой): **0.23**



Профиль

(AdvHat: -)

Близость (оригинал): **0.54**

Профиль

(AdvHat: +)


Близость (оригинал): **0.11**

Близость (другой): **0.27**



Состязательные примеры для распознавателя лиц ArcFace: результат

Детали: статья⁴² (ICPR-2020) и видео-демонстрация⁴³.




⁴²Komkov S. et al. "Advhat: Real-world adversarial attack on arcface face id system." 2019

⁴³<https://www.youtube.com/watch?v=a4iNg0wWBsQ>



Состязательные примеры для распознавателя лиц ArcFace: черно-белые патчи⁴⁴ (IEEE-2019)

- Комбинация двух предыдущих подходов:
 - Цветовой маппинг (штраф за черный цвет)
 - Локальные аффинные проекции на основе подготовленной сетки
- Пример носит семантический характер



Состязательные примеры



⁴⁴Pautov M. et al. "On adversarial patches: real-world attack on ArcFace-100 face recognition system." 2019



Защита от состязательных примеров для систем распознавания в реальном мире⁴⁶

- Большинство состязательных примеров в реальном мире — патчи
 - Предложение: **Adversarial Training (AT)**⁴⁵ в пиксельной области + прямоугольная аугментация
 - Поэтапное AT:
 - ① Позиция серого патча (max функции потерь) via:
 - Полный перебор
 - Max градиента по входу
 - ② MI-FGSM внутри этого патча для поиска раскраски
- Обычная процедура обучения:
- $$\min_{\theta} \mathbb{E}_{x,y}[L(\theta, x, y)]$$
- Состязательное обучение (AT):
- $$\min_{\theta} \mathbb{E}_{x,y}[\max_{r \in \Delta} L(\theta, x + r, y)]$$



⁴⁵ Goodfellow I. et al. "Explaining and harnessing adversarial examples." 2014

⁴⁶ Wu T. et al. "Defending Against Physically Realizable Attacks on Image Classification." 2019




Black-box восстановление лица по вектору признаков

- Black-box модель $M: M(x) = y$, где
 - x — входное фото лица
 - y — его векторное представление (эмбеддинг)
- **Задача:** восстановить x' , сохраняя личность x
- **Ранее:** использование функции потерь MSE и метрик на признаках / GAN (NBNet⁴⁷)
- **Здесь:** метод оптимизации нулевого порядка для нахождения x' : $M(x') \approx M(x)$
 - В качестве M используется: ArcFace
 - Тест независимым критиком: FaceNET⁴⁸
 - Функция потерь (близость):
 $1 - \cos(M(x'), M(x))$
 - Добавка: $(\|M(x')\|_2 - \|M(x)\|_2)^2$

- **Главная сложность:** огромное пространство поиска
- **Решение:** использование априорной информации о лице — 2D-гауссианы

$$G(x, y) = A \cdot e^{\frac{(x-x_0)^2}{2\sigma_1^2} + \frac{(y-y_0)^2}{2\sigma_2^2}}$$



$$(x_0, y_0, \sigma_1, \sigma_2, A) = (56, 72, 22, 42, 1)$$


⁴⁷ Mai G. et al. "On the reconstruction of face images from deep face templates." 2018

⁴⁸ Schroff F. et al. "Facenet: A unified embedding for face recognition and clustering." 2015.




Black-box восстановление лица по вектору признаков: трюки

- Даже использование априорной информации недостаточно
- **Трюк1:** Использовать вертикальную симметрию лица \Rightarrow ищем только половину лица
- **Трюк2:** Для сохранения личности обычно цвет не нужен \Rightarrow ищем только 1 цветовой канал вместо 3



- **Инициализация:** Что взять за начальное приближение?
- **Обычно:** другое лицо (решение может быть смещено)
- **Можно:** оптимальный 2D-гауссиан (как раз нужна добавка на разность норм)



Симметрия, без симметрии, в цвете



Black-box восстановление лица по вектору признаков: алгоритм и примеры

Алгоритм

Algorithm 1 Face recovery algorithm

INPUT: target face embedding y , black-box model M , loss function L , $N_{queries}$

```
1:  $X \leftarrow 0$ 
2: Initialize  $G_0$ 
3: for  $i \leftarrow 0$  to  $N_{queries}$  do:
4:   Allocate image batch  $\mathbf{X}$ 
5:   Sample batch  $\mathbf{G}$  of random gaussians
6:    $\mathbf{X}_j = X + G_0 + \mathbf{G}_j$ 
7:    $\mathbf{y}' = M(\mathbf{X})$ 
8:    $ind = \operatorname{argmin} \left( L(\mathbf{y}'_i, y) \right)$ 
9:    $X \leftarrow X + \mathbf{G}_{ind}$ 
10:   $G_0 \leftarrow 0.99 \cdot G_0$ 
11:   $i \leftarrow i + \text{batchsize}$ 
12: end for
13:  $X \leftarrow X + G_0$ 
```

OUTPUT: reconstructed face X


Примеры

Our method:							
ArcFace:	0.97	0.97	0.94	0.97	0.85	0.73	
FaceNet:	0.70	0.75	0.72	0.78	0.38	-0.09	
NBNet (WB):							
ArcFace:	0.17	0.21	0.12	0.26	0.06	0.09	
FaceNet:	0.02	0.32	0.25	0.46	-0.01	0.35	
NBNet (RGB):							
ArcFace:	0.28	0.46	0.34	0.54	0.12	0.21	
FaceNet:	0.59	0.53	0.44	0.74	0.18	0.41	
Original:							



Black-box восстановление лица по вектору признаков: результат

Детали: статья⁴⁹ (ECCV-2020) и видео-демонстрация⁵⁰.



⁴⁹Razzhigaev A. et al. "Black-Box Face Recovery from Identity Features." 2020

⁵⁰<https://www.youtube.com/watch?v=s0rTcqRTw2A>

Заключительные выводы

- На данный момент СНС (в целом) работают гораздо лучше человека
- СНС неустойчивы (по входу)
- Перенести состязательный пример в реальный мир непросто
- Однако можно сломать даже супер навороченные системы распознавания лиц, имея лишь черно-белую бумажку с обычного принтера
- ℓ_0 -оптимизация + EOT + TV обязательны
- Состязательное обучение может помочь в защите от состязательных примеров
- Изображения лиц могут быть восстановлены по векторам признаков даже в black-box манере



Присоединяйтесь к нам!

Кого мы ждем:

- Выпускники аспирантуры 2019-2021 годов
- Победители и призеры таких международных соревнований как ICPC, IMC, CTF, Kaggle, IMO, IOI, ICHO, IPHO etc.
- Техническое образование (информационные технологии, математика, физика, радиотехника, системы связи, информационная безопасность и др.)
- Английский на уровне "intermediate" и выше



Москва



Санкт-Петербург



Нижний Новгород



Новосибирск

Наши направления:

- Nonlinear algorithm development
- Wireless communication technologies
- Computer Vision with Deep Learning
- Math Library optimization
- Automatic program repair
- Compiler optimizations
- Automatic speech recognition
- AI databases and AI enabled systems
- Distributed and Parallel software
- Image/Video signal processing
- Software engineering and innovation
- Automated machine learning & Model optimization
- Computer architecture

Резюме можно выслать на почту:
rrihr@huawei.com



<https://career.huawei.ru/rri/>

Inspired by science to connect the world!

Looking forward to seeing your application



Вопросы к аудитории

- ❶ В чем, на ваш взгляд, главная причина существования состязательных примеров (кроме приведенной ранее)?



Вопросы к аудитории

- ① В чем, на ваш взгляд, главная причина существования состязательных примеров (кроме приведенной ранее)?
- ② Приведите нетривиальные примеры борьбы с проклятием размерности в реальных задачах компьютерного зрения



Вопросы к аудитории

- ➊ В чем, на ваш взгляд, главная причина существования состязательных примеров (кроме приведенной ранее)?
- ➋ Приведите нетривиальные примеры борьбы с проклятием размерности в реальных задачах компьютерного зрения
- ➌ Зачем нужны проекции для генерации реальных примеров, и зачем через них пропускать градиенты?



Вопросы к аудитории

- ① В чем, на ваш взгляд, главная причина существования состязательных примеров (кроме приведенной ранее)?
- ② Приведите нетривиальные примеры борьбы с проклятием размерности в реальных задачах компьютерного зрения
- ③ Зачем нужны проекции для генерации реальных примеров, и зачем через них пропускать градиенты?
- ④ Какие бы вы предложили варианты физических примеров для интересной практической задачи (кроме систем распознавания/детекции лиц) и, соответственно, защиты от них?



Вопросы к аудитории

- ① В чем, на ваш взгляд, главная причина существования состязательных примеров (кроме приведенной ранее)?
- ② Приведите нетривиальные примеры борьбы с проклятием размерности в реальных задачах компьютерного зрения
- ③ Зачем нужны проекции для генерации реальных примеров, и зачем через них пропускать градиенты?
- ④ Какие бы вы предложили варианты физических примеров для интересной практической задачи (кроме систем распознавания/детекции лиц) и, соответственно, защиты от них?
- ⑤ Какие вообще перспективы биометрии в важных приложениях? Чем можно заменить?



Спасибо за внимание!

